

PO DELAY ROOT CAUSE ANALYZER

Reporte de Fase 1: Data Pipeline & Análisis Exploratorio de Datos (EDA)

1. Objetivo y Contexto del Proyecto

1.1 Alcance de esta Fase

El objetivo de la primera fase del proyecto *PO Delay Root Cause Analyzer* fue cargar, limpiar, validar y explorar el dataset de Purchase Orders (POs), para entregar como producto final un DataFrame limpio con todos los deltas de tiempo calculados, los flags de calidad de datos levantados y las métricas operacionales enriquecidas. Este DataFrame limpio (`df_clean.csv`) y la función reutilizable (`pipeline_core.py`) constituyen el insumo base sobre el que se construirá el clasificador de causa raíz en la Fase 2.

1.2 Dataset: `po_root_cause_synthetic.csv`

Para este análisis se utiliza el archivo *po_root_cause_synthetic.csv*, un conjunto de datos sintético diseñado para simular el ciclo de vida completo de las órdenes de compra dentro de una operación de retail. El dataset comprende 400 registros de POs únicos (PO_NBR del 100000 al 100399), todos con estatus final cerrado o completado (PO_STATUS_CD = C), lo que garantiza un ciclo de vida observable y analizable de principio a fin.

El ecosistema operativo representado incluye:

- Proveedores (Vendors): 10 proveedores únicos.
- Centros de Distribución (DCs): 8 centros estratégicos distribuidos geográficamente.
- Transportistas (Carriers): 9 empresas de transporte.

A nivel técnico, el dataset cuenta con 39 columnas totales que abarcan identificadores, marcas de tiempo (timestamps), cantidades, flags y métricas de rendimiento. La variable objetivo principal es IS_LATE (Y/N), que determina si una orden fue recibida con retraso respecto a su fecha estimada de llegada (STA_DT).

2. Carga e Inventario de Columnas.

2.1 Proceso de Carga del CSV.

La carga del dataset se implementó de forma que garantiza compatibilidad en un entorno local (VSCode), adoptando se adopta el siguiente flujo:

- Se determina la raíz del repositorio (REPO_ROOT) de forma dinámica mediante Path.cwd(), adaptándose automáticamente si el script se ejecuta desde el subdirectorio del sprint.
- Se intenta cargar la ruta del CSV desde la variable de entorno PO_CSV_PATH definida en el archivo .env del proyecto. Si no existe dicha variable, se utiliza la ruta por defecto: data/raw/po_root_cause_synthetic.csv.
- Se verifica la existencia física del archivo antes de cargarlo. En caso de no encontrarlo, se lanza un FileNotFoundError con instrucciones claras para el usuario.
- Se lee el CSV con pandas (pd.read_csv), habilitando low_memory=False para evitar inferencias de tipos incorrectas en columnas mixtas.

2.2 Diagnóstico Inicial: Análisis de Calidad de Datos

Inmediatamente después de la carga, se genera un reporte automático de calidad que reporta para cada columna: tipo de dato (dtype), número y porcentaje de valores nulos, y número de valores únicos. Este inventario revela dos escenarios operativos distintos de datos faltantes:

- PREVIOUS_REQUEST_DT: 337 nulos (84.25%) — NULO POR DISEÑO. Esta variable solo registra un valor cuando una cita ha sido explícitamente reprogramada. La presencia de nulos es un comportamiento esperado y representa un flag implícito de no-reprogramación.
- TRAILER_ARRIVE_DT: 27 nulos (~6.75%) — NULO POR ERROR DE CAPTURA. Representa el problema de calidad más crítico del repositorio. Sin el registro de la hora de llegada real del tráiler, es matemáticamente imposible clasificar si el retraso operativo fue responsabilidad del carrier o del DC. Estas 27 POs quedan marcadas como "Unclassifiable".

Adicionalmente, la variable REASON_DSC presenta 9 valores nulos en órdenes tardías, es decir, existe un retraso documentado sin causa raíz capturada en el sistema.

3. Limpieza de Datos: Función clean_po_data()

3.1 Contexto: Reglas de Delay por Etapa

Todo el diseño de la función de limpieza y enriquecimiento está directamente fundamentado en el documento de referencia entregado al inicio del proyecto: "kickoff_po_root_cause: Reglas de delay por etapa". Dicho documento establece la lógica de clasificación en tres grandes bloques operativos:

- *Stage 1 — Pre-Arrival (Vendor / Carrier): Cubre los retrasos generados antes de que el tráiler llegue al DC. Se incluyen el push de aprobación (APPROVED_DT > STA_DT), el late shipment del proveedor (VENDOR_SHIP_DT > STA_DT), el carrier miss (TRAILER_ARRIVE >*

APPROVED_DT + umbral) y la reprogramación (CURRENT_APPROVED ≠ FIRST_APPROVED). El responsable es el Vendor o el Carrier según qué campo exceda el umbral.

- *Stage 2 — At the DC (DC Controlled): Cubre los retrasos que ocurren una vez que el tráiler ya llegó pero la recepción se retrasó. Incluye Yard Congestion (CHECKIN_DT – TRAILER_ARRIVE > 4 hrs) y Long Dock (CHECKOUT_DT – CHECKIN_DT > 6 hrs). El responsable es DC Operations.*
- *Cross-Stage / Prioridad: Captura condiciones que se superponen a las etapas anteriores, como la recepción tardía como KPI principal (RECPT_DT > STA_DT), el Short Ship (CASES_SHIPPED / CASES_ORDERED < 0.9), el Hot PO Delayed (HOT_PO_FLAG = 1 con cualquier retraso) y el Short Lead Time (STA_DT – PO_DT < 3 días). Un mismo PO puede tener múltiples causas.*

Adicionalmente, el documento señala que el KPI principal es RECPT_DT > STA_DT: si la recepción fue a tiempo, el PO no tiene delay independientemente de lo que ocurrió en el camino. El campo REASON_DSC es la anotación humana del staff del DC y sirve para comparar (matches y mismatches) contra la clasificación automática.

3.2 La Función `clean_po_data()` — Motor del Pipeline

La función `clean_po_data` actúa como el motor principal de procesamiento y transformación del dataset crudo. Recibe como entrada el DataFrame original (`df_raw`) y devuelve un DataFrame enriquecido con timestamps parseados, flags de calidad, métricas operacionales, deltas de tiempo y banderas de clasificación. Está diseñada para ser reutilizable en cualquier fase posterior del proyecto —puede ser importada directamente desde `pipeline_core.py`— garantizando reproducibilidad completa del proceso.

El flujo interno de la función se divide en cinco etapas consecutivas:

Etapas 1 — Estandarización de Fechas y Tiempos

El primer paso homogeneiza el formato de 13 columnas críticas de timestamps. Variables como la fecha de creación de la orden (`PO_DT`), fechas de citas de entrega y registros del DC (arribo del tráiler, check-in, check-out) se convierten explícitamente al tipo `datetime`. Las cadenas corruptas o con formatos inválidos se tratan de forma segura como nulos (`NaT`) mediante coerción (`errors="coerce"`).

Las 13 columnas procesadas son: `PO_DT`, `STA_DT`, `RECPT_DT`, `REQUESTED_DT`, `FIRST_SUBMITTED_DT`, `DT_APPT_FIRST_APPROVED`, `APPROVED_DT`, `DT_APPT_CURRENT_APPROVED`, `PREVIOUS_REQUEST_DT`, `TRAILER_ARRIVE_DT`, `CHECKIN_DT`, `CHECKOUT_DT`, `TRAILER_DEPART_DT`.

Etapas 2 — Flags de Calidad y Confiabilidad de Datos

Se construyen tres indicadores de auditoría interna para evaluar la integridad de cada registro:

- `_trailer_arrive_null`: Detecta si el arribo del transportista no fue registrado.
- `_ts_issue`: Activa la alerta si ocurre cualquier inconsistencia cronológica: check-in anterior a la llegada del tráiler, checkout antes del check-in, o recepción previa al check-in.
- `_data_reliable`: Etiqueta como verdaderamente confiables únicamente los registros que pasaron ambas auditorías con éxito (sin nulo de arribo y sin error de timestamp).

Etapas 3 — Métricas Operacionales

Se calculan indicadores de desempeño comercial y logístico:

- `_rescheduled`: Compara la cita actual (`DT_APPT_CURRENT_APPROVED`) contra la primera aprobada (`DT_APPT_FIRST_APPROVED`) para detectar cambios de agenda.
- `_fill_rate`: Mide el porcentaje de cajas enviadas (`NUM_CASES_SHIPPED`) contra las pedidas (`NUM_CASES_ORDERED`). El resultado se recorta al rango 0–1 para evitar valores anómalos.
- `_short_ship`: Dispara una alerta si el fill rate cae por debajo del umbral crítico del 90%.

Etapas 4 — Cálculo de Deltas y Tiempos Logísticos

Para cuantificar con precisión los cuellos de botella, se calculan 7 nuevas métricas de tiempo convirtiéndolas dinámicamente a horas o días según la naturaleza de la métrica:

- `lead_time_days`: Días entre `PO_DT` y `STA_DT` (tiempo de tránsito comprometido).
- `carrier_lag_hrs`: Horas entre `APPROVED_DT` y `TRAILER_ARRIVE_DT` (retraso de llegada del carrier vs. su cita).
- `yard_wait_calc_hrs`: Horas entre `TRAILER_ARRIVE_DT` y `CHECKIN_DT` (espera en patio, recortada a mínimo 0).
- `dock_calc_hrs`: Horas entre `CHECKIN_DT` y `CHECKOUT_DT` (tiempo de descarga en andén).
- `total_dc_hrs`: Horas entre `TRAILER_ARRIVE_DT` y `CHECKOUT_DT` (estadía total dentro del DC).
- `appt_lead_days`: Días entre `APPROVED_DT` y `STA_DT` (anticipación con que se agendó la cita).
- `delay_days_calc`: Días entre `RECPT_DT` y `STA_DT` recortados a mínimo 0 (retraso real calculado).

Etapas 5 — Clasificación por Etapa y Flags de Alerta (Reglas de Negocio)

Finalmente, se configuran umbrales operativos fijos —derivados directamente de las "Reglas de delay por etapa"— para automatizar la detección de problemas logísticos:

- `flag_yard_congestion`: Activa cuando `YARD_WAIT_HRS > 4.0` horas (umbral de congestión en patio).

- **flag_dock_backlog:** Activa cuando DOCK_HRS > 6.0 horas (umbral de saturación de andén).
- **flag_carrier_miss:** Activa cuando carrier_lag_hrs > 4.0 horas (incumplimiento del transportista).
- **flag_short_lead_time:** Activa cuando lead_time_days < 3.0 días (orden urgente fuera del ciclo normal).
- **flag_hot_late:** Activa cuando HOT_PO_FLAG = 1 y IS_LATE = "Y" simultáneamente (orden crítica con retraso).

4. EDA — Análisis Exploratorio de Datos


4.1 Distribución Global de Delays

El análisis revela una tasa de entregas tardías del 41.25%, un indicador críticamente elevado para cualquier operación de cadena de suministro en el sector retail. En los mercados comerciales modernos, el estándar de eficiencia bajo la métrica On Time In Full (OTIF) exige niveles de puntualidad superiores al 95%. Operar con casi la mitad de los pedidos fuera de tiempo genera un impacto financiero directo.

El análisis visual del histograma de "Días de retraso (solo POs tardíos)" revela un comportamiento operativo crítico: la distribución del delay no presenta concentración en los primeros días ni una cola larga hacia la derecha. Por el contrario, muestra una distribución notablemente simétrica y casi uniforme en todo el espectro de tiempo analizado. La Media (2.87 días) y la Mediana (2.90 días) están prácticamente superpuestas en el centro, confirmando que los datos se distribuyen equitativamente a ambos lados, sin sesgos hacia retrasos cortos o largos.

Esta simetría rompe la suposición común de que los retrasos grandes son eventos aislados. En este dataset, un retraso severo de 5 días es tan frecuente y probable como un retraso leve de 1 día, describiendo un proceso logístico fuera de control estadístico. Para el diseño del dashboard, esto implica que no se deben buscar "casos aislados de alta severidad", sino que las alertas deben enfocarse en desviaciones estructurales agrupadas por carrier o vendor.

Gráfico 1. Distribución Global de Purchase Orders.




4.2 Análisis por Distribution Center (DC)

Para evaluar el impacto de la infraestructura física en el cumplimiento de las POs, se calcularon métricas de rendimiento para cada uno de los 8 centros de distribución. Los hallazgos más relevantes son los siguientes:

- Phoenix DC lidera el promedio de días de retraso: Se consolida como la ubicación más crítica bajo la métrica DELAY_DAYS. Su posición puede estar fundamentada en un volumen de POs más alto, un mix regional de proveedores con bajo cumplimiento, distancias de tránsito más largas, o ineficiencias puramente operativas internas.
- Heterogeneidad estructural: La tasa de entregas tardías muestra alta variabilidad geográfica. Algunas ubicaciones superan el 45% de incumplimiento mientras que los nodos más eficientes se mantienen por debajo del 35%.
- Desacople de factores: El DC con mayor tiempo promedio de espera en patio no coincide necesariamente con el de peor tasa de entregas tardías, indicando que la saturación de accesos no es la única causa del retraso final.
- Eficiencia interna en andenes: Ningún DC supera el umbral crítico de 6.0 horas en zona de descarga en promedio, descartando el dock backlog como detonante principal de los retrasos a escala global.

La disparidad de rendimiento entre DCs es uno de los hallazgos más reveladores. Una parte significativa del bajo desempeño puede estar ligada a factores externos al almacén, como el mix de socios comerciales asignados a cada región.

Gráfico 2. Performance por Distribution Center.



4.3 Análisis por Vendor y Carrier

La evaluación de socios comerciales se realiza mediante un análisis bidimensional de puntualidad y volumen de entrega, estableciendo bases objetivas para decisiones contractuales.

Desempeño de Vendors

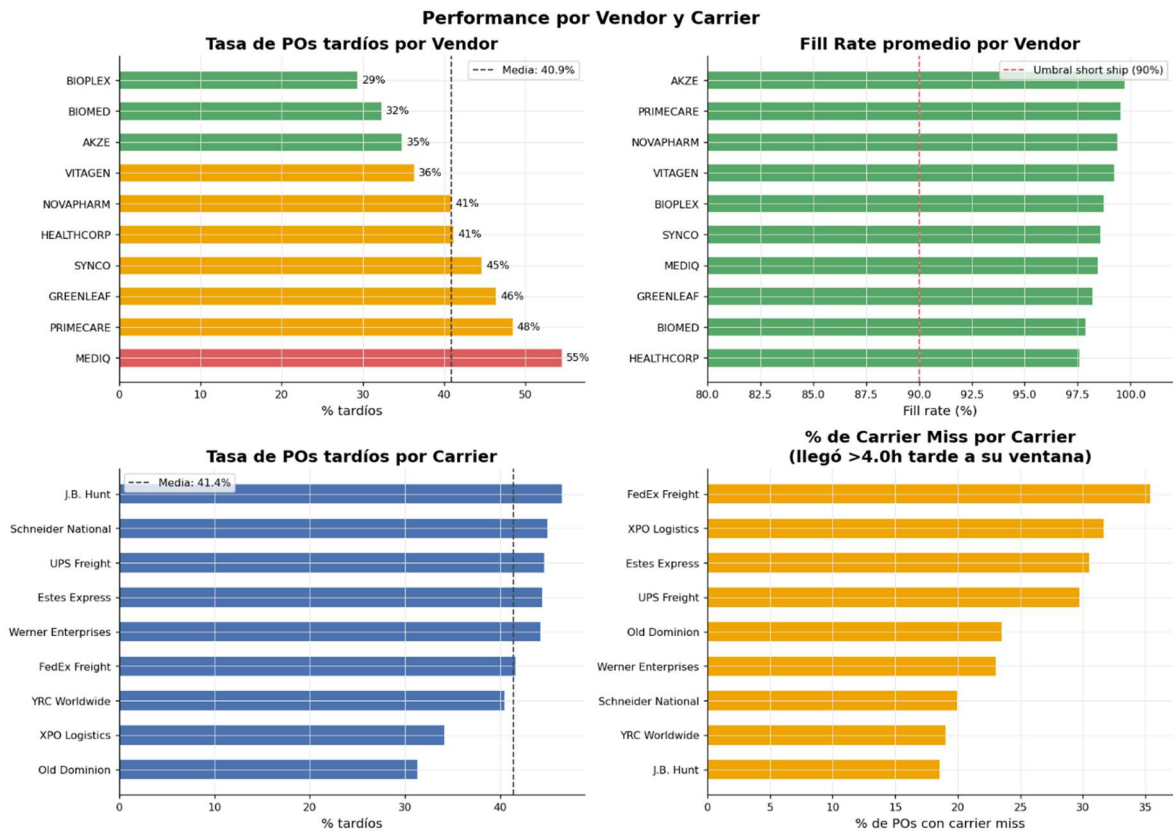
El comportamiento de los proveedores revela un ecosistema heterogéneo. El proveedor MEDIQ se consolida como el caso más grave de riesgo contractual, con una tasa de tardanza del 55% —más de la mitad de sus camiones llegan fuera de ventana— a pesar de que su Fill Rate roza el 98.5%. Siete de los diez proveedores superan la media general de retrasos (40.9%) o se encuentran en zona de advertencia. Únicamente BIOPLEX, BIOMED, VITAGEN y AKZE muestran niveles de puntualidad moderadamente aceptables.

El cruce de datos redirige la atención hacia la logística de transporte: si un proveedor surte casi el 100% de las cajas pero llega tarde, la causa apunta a ineficiencias en el proceso de scheduling o al desempeño deficiente de la empresa de transporte contratada para esa cuenta.

Desempeño de Carriers

El indicador flag_carrier_miss —porcentaje de órdenes donde el transportista arriba con más de 4 horas de retraso respecto a su cita aprobada— es el KPI definitivo para delimitar la responsabilidad del transporte. Al analizar las 9 empresas, se detectó variación considerable en los niveles de cumplimiento. Un transportista con alto índice de citas perdidas inyecta ineficiencias financieras ocultas: reprogramación de muelles de urgencia, horas extra al personal, congestión física del patio y efecto cascada sobre las POs subsecuentes.

Gráfico 3. Performance por Vendor y Carrier.



4.4 Reason Code Analysis + Detección de Mismatches

Los datos analíticos revelan una vulnerabilidad crítica en la integridad del sistema de registro: casi la mitad de los retrasos operativos están mal etiquetados. Específicamente, el 48.5% de las POs tardías (80 de 165) presentan un Reason Code inconsistente frente a la evidencia cronológica real de los timestamps.

Al evaluar la distribución de las inconsistencias por categoría:


- Concentración del error: Las etiquetas de "Rescheduled by vendor" (34 incidentes) y "Vendor delayed shipment" (28 incidentes) acaparan la mayoría de las contradicciones, sumando 62 de los 80 mismatches detectados.
- El insight operativo: El personal del DC utiliza los códigos imputables al proveedor como un "comodín" ante incidencias. Mientras el sistema registra que el proveedor falló, los timestamps físicos demuestran que la mercancía o el transportista ya estaban en patio. Esto evidencia un vicio en el proceso de captura manual que castiga injustamente los scorecards de los socios comerciales.

Radiografía Geográfica de los Mismatches

- Dallas (DL) y Phoenix (PX): Con 13 casos cada uno, son los focos rojos más críticos de órdenes etiquetadas incorrectamente como "Rescheduled by vendor".
- Chicago (CH): 10 casos de mismatch concentrados en la misma categoría.
- Patrón sistemático: En la totalidad de los nodos logísticos, las columnas de fallas del proveedor concentran los valores más altos. Al presentarse como constante homogénea en todos los DCs, se confirma que es un vicio estructural en el proceso de recepción, no un fenómeno local.

El impacto directo para el negocio es la erosión del poder de negociación contractual: al emitir penalizaciones basadas en datos erróneos.

Gráfico 4. Reason Code Analysis y detección de mismatches.



5. Conclusiones del Análisis Exploratorio

El Análisis Exploratorio de Datos realizado sobre el dataset de 400 órdenes de compra completadas revela un diagnóstico operativo de alta complejidad que va mucho más allá de la simple constatación de que cuatro de cada diez pedidos llegan tarde. Lo que el EDA expone es una cadena de suministro que enfrenta simultáneamente tres tipos de problemas distintos: uno de desempeño, uno de estructura y uno de integridad informacional. Entender esta trilogía es el punto de partida esencial para construir cualquier solución analítica que genere valor real para el negocio.

La primera dimensión del diagnóstico es la más directa. La tasa de entregas tardías del 41.25% no es, por sí sola, el hallazgo más preocupante. Lo verdaderamente revelador es el comportamiento estadístico de esos retrasos. La distribución de los días de delay para las 165 POs tardías mostró una forma casi uniforme, con media y mediana prácticamente superpuestas en torno a los 2.87 días. Esta simetría tiene una implicación operativa contundente: el sistema logístico no está experimentando picos esporádicos de ineficiencia. Está operando de forma estructuralmente descontrolada.

La segunda dimensión del diagnóstico emerge del análisis por centros de distribución. Phoenix DC se posiciona como el nodo más crítico en días promedio de retraso, pero el análisis subraya algo más importante que ese hecho aislado: la alta variabilidad entre DCs no puede atribuirse únicamente a la gestión interna de cada almacén. La distribución de socios comerciales por región es un factor estructural que modula el desempeño de cada nodo de manera significativa.

El análisis por socio comercial añade una tercera capa de complejidad al diagnóstico. El caso de MEDIQ es el ejemplo paradigmático de la desconexión entre calidad de producto y puntualidad de entrega: un fill rate del 98.5% coexiste con una tasa de tardanza del 55%. Esta combinación es, desde la perspectiva de la gestión contractual, una trampa analítica peligrosa. Si el equipo de compras evalúa a sus proveedores únicamente por la completitud de los envíos, MEDIQ parecerá un socio excelente. Si se incluye la dimensión de puntualidad, se convierte en el mayor riesgo contractual de la red.

Quizás el hallazgo más disruptivo del EDA es el de los mismatches en los Reason Codes. Que el 48.5% de las POs tardías estén mal etiquetadas no es un problema técnico de limpieza de datos: es una falla de gobernanza informacional que tiene consecuencias operativas y legales de primer orden.

Para el proyecto, este hallazgo tiene una consecuencia directa en la arquitectura del clasificador de Fase 2. No se puede usar el campo REASON_DSC como variable de entrenamiento confiable para un modelo supervisado sin antes construir una lógica de validación que identifique y corrija estos mismatches.

6. Output Generado y Próximos Pasos

La función reutilizable produce un dataset limpio y enriquecido 'df_clean.csv' con 400 filas y 57 columnas (39 originales + 18 nuevas). Almacenado en data/processed/.

- pipeline_core.py: Módulo Python con la función reutilizable clean_po_data(). Importable en cualquier notebook o script posterior del proyecto mediante: `from pipeline_core import clean_po_data`.